

SVM

☰ exam	개인학습
# Lec	118



01) SVM의 이해

01_Margin 최대화


- ☞ 이 범주 분류 문제
- ☞ SVM의 분류
- ☞ 비용함수
- ☞ 라그랑주 승수
- ☞ KKT 조건

01) SVM의 이해

01_Margin 최대화

☞ 이 범주 분류 문제

- 이 범주 문제를 풀기 위해 많은 노력을 하였음
- 기존 의사결정 나무의 경우는 수직으로만 분류가 가능해 많은 한계가 있었음
- SVM은 Margin을 최대화 하는 초평면을 찾는 문제로 이 범주 분류 문제를 접근하고 있음
- Margin을 최대화한다는 것은 데이터를 분류할 수 있는 경계면의 수를 낮출 수 있다는 것을 의미 → 구조적 위험을 감소 시킬 수 있음
- 특히 차원을 늘리는 Kernel Trick을 이용하여 고차원으로 매핑하여 이 범주 분류 문제를 풀 수 있음



☞ SVM의 분류

	Hard margin?	Soft margin?
Linearly separable?	Basic form (Case 1)	Introduce penalty terms (Case 2)
Linearly non-separable?	Utilize Kernel Trick	Introduce penalty terms Utilize Kernel Trick (Case 3)

- SVM은 상황에 따라 종류를 구분할 수 있음
- 선형분리가 가능하고, 관측치가 마진을 넘는 것을 허용하지 않으면 Basic form(기본 선형 모델이다)
- 선형분리가 가능하고, 관측치가 마진을 넘는 것을 허용하면 패널티를 부여하는 소프트 마진 모델이다.
- 선형분리가 불가능하고, 관측치가 마진을 넘는 것을 허용하면 패널티도 부여하고 커널트릭을 이용하여야 한다.
- 선형분리가 불가능하고 관측치가 마진을 넘는 것을 허용하지 않으면 커널트릭을 이용한 모델이다.

㉠ 비용함수

- SVM softmargin모델에서는 관측치를 허용하다 보니 잘못 분류된 데이터에 대해 패널티의 값을 조정하는 C(비용함수)가 존재함
- C 하이퍼파라미터는 마진과 오류에 대한 균형을 조정을 하는 역할을 한다.
- C가 크면 → 패널티를 줄이는 방향으로 학습을 해야 한다.
- C의 값이 작으면 → 패널티를 받더라도 마진을 넓게 잡도록 학습한다.

$$\text{minimize } \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i$$

㉠ 라그랑주 승수

- SVM에서는 최적화 문제를 다루다 보니 최적화 관련 개념이 많이 나옴
- 특히 우리가 마진을 최대화 하는 식을 목적함수식으로 설정하다 보니 문제를 푸는 데 많은 어려움이 있음
- 그래서 우리는 Max문제를 Min문제로 만들어 문제를 단순화하고자 함
- Max문제를 Min문제로 변환하기 위해서는 라그랑주 승수법이 사용된다.
- 라그랑주 승수법은 제약조건이 있는 최적화 문제를 푸는 수학적 기법이다.
- 제약조건을 가진 다 변수 함수 최적화 문제를 풀 때 사용함
- $L(x, \lambda) = f(x) + \lambda g(x)$
- $f(x)$ = 목적함수, $g(x)$ = 제약조건
- 라그랑지안 함수 $f(x)$ 와 $g(x) = 0$ 으로 사용해서 정의

- 기울기를 계산, 목적함수와 제약식의 기울기를 구하고, 그 기울기가 0이 되는 점이 최적해가 발생한다.

◐ KKT 조건

- 라그랑주 승수법을 사용하여 최적화를 진행하기 위해서는, 라그랑지안 함수의 극값을 찾는 것이 중요
- KKT 최적화 조건이 라그랑주 승수법을 사용할 때 반드시 만족해야 하는 제약조건이다.
- 목적함수의 기울기와 제약조건의 기울기가 균형을 이룰 때, 극 값이 발생(정지 조건)
- $g(x)=0$ 인 문제의 유효성 제약조건을 만족
- 듀얼문제의 유효성 $\lambda \geq 0$
- 라그랑주 승수가 0이 아닌 경우, 제약조건 $g(x)$ 가 반드시 활성화 되어야 한다.