


IMPORTANT (EQUATIONS, LAWS, ETC.)

NOTES

1. XG Boosting의 개념

- Gradient Boosting 알고리즘을 확장하여 효율성과 성능 극대화를 위한 방법
- 여러 개의 결정 트리의 조합
- 독립적으로 각 트리가 작동하는게 아니라 이전 트리의 에러를 보완하도록 설계
- 최종 예측은 모든 트리의 결과 합산해서 얻게 되는 것



2. XG Boosting의 특징

- 1) 정규화 - 과적합 방지
- 2) 병렬 처리 - 학습 속도를 개선해준다.
- 3) 조기 종료 - 불필요한 것들 추가 학습 방지
- 4) 손실 함수를 2차 테일러 근사하여 더 정확한 최적화 진행

3. Gradient Boosting과 XG Boosting의 차이

특징	Gradient Boosting (GB)	XGBoost
기본 알고리즘	Gradient Boosting 기반.	Gradient Boosting 기반.
손실 함수 최적화	1차 미분(Gradient)만 사용.	2차 테일러 근사(Taylor Expansion)를 사용하여 더 정밀한 최적화.
정규화	별도 정규화 기능 없음.	L1 및 L2 정규화로 모델 복잡도를 제어하여 과적합 방지.
병렬 처리	기본적으로 순차적 트리 생성(병렬 처리 없음).	병렬 처리를 통해 분할 계산 등에서 속도 향상.
결측값 처리	기본적으로 결측값 처리 기능 없음(사용자가 직접 처리).	결측값을 자동 처리하며 최적의 분할 방향 결정.
조기 종료 (Early Stopping)	기본적으로 지원하지 않음.	조기 종료를 통해 불필요한 반복 방지.
리프 분할 점수 계산	잔차(Residual)를 기반으로 분할.	Gain(이득)을 계산하여 분할 기준을 최적화.
속도	상대적으로 느림.	병렬 처리 및 최적화를 통해 빠름.

4. XG Boosting의 Bias와 Variance

$$L(\phi) = \sum_i l(\hat{y}_i, y_i) + \frac{\lambda}{2} \sum_k \Omega(\phi_k)$$

where $\Omega(\phi) = \gamma T + \frac{1}{2} \sum_j w_j^2$

↳ 리프의 노수 제어하는 것
↳ 리프 노가 추가되는 속도 조절 가능함 (트리의 크기를 제한하여 과적합 방지)

5. XG Boost의 손실 함수

- 1) At the t iteration

$$l(\hat{y}_i, y_i) = l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i))$$
- 2) 2차 테일러 근사를 사용하여 손실 함수를 근사한다.

$$l(y_i, \hat{y}_i^{(t-1)} + f_t(x_i)) \approx l(y_i, \hat{y}_i^{(t-1)}) + g_t f_t(x_i) + \frac{1}{2} h_t f_t^2(x_i)$$

Hessian : 2차 미분에 대한 2차 도함수
Gradient : 1차 미분에 대한 1차 도함수

$g_t = \partial_{\hat{y}} l(y_i, \hat{y}_i^{(t-1)})$
 ↳ 손실 함수의 1차 미분 값 → 손실 함수의 변화 방향을 나타냄
 $h_t = \partial_{\hat{y}^2} l(y_i, \hat{y}_i^{(t-1)})$
 ↳ 손실 함수의 2차 미분 값으로, 변화 방향의 곡률 (변화 속도를 나타냄)
 ↳ h_t 최적화를 수행할 때, 학습의 안정성, 속도를 조절하는 데 사용하게 된다.

6. 트리가 최적화하기 위해서 목적 함수를 제한 수식

< 첫 번째 목적 함수 >

$$L^{(t)} \approx \sum_{i=1}^n [l(y_i, \hat{y}_i^{(t-1)}) + g_t f_t(x_i) + \frac{1}{2} h_t f_t^2(x_i)] + \Omega(f_t)$$

↳ 이전 트리의 학습한 능력 예측값들
↳ 새로운 트리가 학습할 때의 학습 한계도
↳ 최적화에서 제약을 줘야 함

↳ 새로운 트리를 학습하는 역할
↳ 1차 미분에 관한 것.
↳ 새 트리에 불일치를 최소화하는 등화항

$$L^{(t)} = \sum_{i=1}^n [g_t f_t(x_i) + \frac{1}{2} h_t f_t^2(x_i)] + \Omega(f_t)$$

$$L^{(t)} = \frac{\lambda}{2} [g_t f_t(x_i) + \frac{1}{2} h_t f_t^2(x_i)] + \gamma T + \frac{1}{2} \lambda \sum_{j=1}^T w_j^2$$

$$= \frac{\lambda}{2} [\sum_{i \in I_1} g_i x_i w_j + \frac{1}{2} (\sum_{i \in I_1} h_i x_i + \lambda) w_j^2] + \gamma T$$

< Find the minimum >

$$\partial_{w_j} L^{(t)} = 0$$



< Solution >

$$w_j^* = - \frac{\sum_{i \in I_j} g_i}{\sum_{i \in I_j} h_i + \lambda}$$

< Minimum Value of the Loss >

$$L^{(t)}(q) = -\frac{\lambda}{2} \frac{(\sum_{i \in I_1} g_i)^2}{\sum_{i \in I_1} h_i + \lambda} + \gamma T$$

$$L_{split} = \frac{\lambda}{2} \left[\frac{(\sum_{i \in I_L} g_i)^2}{\sum_{i \in I_L} h_i + \lambda} + \frac{(\sum_{i \in I_R} g_i)^2}{\sum_{i \in I_R} h_i + \lambda} - \frac{(\sum_{i \in I} g_i)^2}{\sum_{i \in I} h_i + \lambda} \right] - \gamma$$

< Find the splits that minimize the loss and the Complexity of the tree >

$$-\frac{GRAD_j^2}{CURV_j + \lambda} \quad -GRAD_j \sim \text{Bias}, \quad -CURV_j \sim \text{Variance}$$

